

Системы искусственного интеллекта

Лекция

Ошибки и функционалы качества



Запорожцев Иван Федорович
zaporozhtsev.if.work@gmail.com

Определение качества для задач...

- Задача регрессии
- Задача бинарной классификации
- Задача нечёткой бинарной классификации
- Задача классификации на несколько классов


Определение качества для задач...

Задача регрессии



Средний модуль отклонения

Mean Absolute Error (MAE), Mean Absolute Deviation (MAD)



$$\text{MAE} = \frac{1}{m} \sum_{i=1}^m |a_i - y_i|$$

$$\sum_{i=1}^m |a - y_i| \rightarrow \min$$


$$a = \text{median}(\{y_i\}_{i=1}^m)$$

$$\sum_{i=1}^m |a - y_i| \rightarrow \min$$

$$a = \text{median}(\{y_i\}_{i=1}^m)$$

$$f(x) = |x - 3| + |x| + |x + 3| + |x + 5|$$



Как видим, функция зависит от четырёх модулей. Нанесём на числовую ось точки, в которых выражения под модулем обращаются в ноль.



	I	II	III	IV	V
	$(-\infty; -5)$	$[-5; -3)$	$[-3; 0)$	$[0; 3)$	$[3; +\infty)$
$x - 3$	—	—	—	—	+
x	—	—	—	+	+
$x + 3$	—	—	+	+	+
$x + 5$	—	+	+	+	+
$f(x)$	$3 - x - x - x -$ $-3 - x - 5$	$-x + 3 - x - x -$ $-3 + x + 5$	$-x + 3 - x + x +$ $+3 + x + 5$	$-x + 3 + x + x +$ $+3 + x + 5$	$x - 3 + x + x +$ $+3 + x + 5$


$$\sum_{i=1}^m |a - y_i| \rightarrow \min$$

$$a = \text{median}(\{y_i\}_{i=1}^m)$$




Средний модуль отклонения

Mean Absolute Error (MAE), Mean Absolute Deviation (MAD)



$$\text{MAE} = \frac{1}{m} \sum_{i=1}^m |a_i - y_i|$$

Если ошибка распределена по Лапласу




$$\frac{1}{m} \sum_{i=1}^m |a - y_i| \rightarrow \min$$

$$a = \text{median}(\{y_i\}_{i=1}^m)$$

Средний квадрат отклонения

Mean Squared Error (MSE)



$$\text{MSE} = \frac{1}{m} \sum_{i=1}^m |a_i - y_i|^2$$

Если ошибка нормально распределена



$$\frac{1}{m} \sum_{i=1}^m |a - y_i|^2 \rightarrow \min$$

$$a = \frac{1}{m} \sum_{i=1}^m y_i$$

Root Mean Squared Error (RMSE) / Root Mean Square Deviation (RMSD)

$$\text{RMSE} = \sqrt{\frac{1}{m} \sum_{i=1}^m |a_i - y_i|^2}$$



Нормированная версия: коэффициент
детерминации R^2

(Coefficient of Determination)

$$R^2 = 1 - \frac{\sum_{i=1}^m |a_i - y_i|^2}{\sum_{i=1}^m |\bar{y} - y_i|^2} \quad \bar{y} = \frac{1}{m} \sum_{i=1}^m y_i$$

Различия MSE и MAE

Устойчивость к выбросам...



Symmetric mean absolute percentage error

SMAPE or sMAPE

$$\text{SMAPE} = \frac{2}{m} \sum_{i=1}^m \frac{|y_i - a_i|}{y_i + a_i} = 100\% \cdot \frac{1}{m} \sum_{i=1}^m \frac{|y_i - a_i|}{(y_i + a_i) / 2}$$

$$\text{MAPE} = \frac{1}{m} \sum_{i=1}^m \frac{|y_i - a_i|}{|y_i|}$$

Метрики в регрессии: минутка кода

```
from sklearn.metrics import r2_score
from sklearn.metrics import mean_absolute_error
from sklearn.metrics import mean_squared_error
from sklearn.metrics import mean_squared_log_error
from sklearn.metrics import median_absolute_error
from sklearn.metrics import explained_variance_score

# R^2
print (r2_score(y, a),
        1 - np.mean((y - a) ** 2) / np.mean((y - np.mean(y)) ** 2))


# MAE
print (mean_absolute_error(y, a),
        np.mean(np.abs(y - a)))

# MSE
print (mean_squared_error(y, a),
        np.mean((y - a) ** 2))

# MSLE
print (mean_squared_log_error(y, a),
        np.mean((np.log1p(y) - np.log1p(a)) ** 2))

# MedAE
print (median_absolute_error(y, a),
        np.median(np.abs(y - a)))
```

Задача бинарной классификации



Сначала – чёткая классификация

«Confusion Matrix» в задаче классификации с двумя классами



NEGATIVE

POSITIVE



алгоритм

Кл. «0»

Кл. «1»

истина

		TRUE NEGATIVE	TYPE 1 ERR FALSE POSITIVE
		TYPE 2 ERR FALSE NEGATIVE	TRUE POSITIVE



```
tn, fp, fn, tp = confusion_matrix(y, a).ravel()
# вычисление tn, ...
```

	$a=0$	$a=1$
$y=0$	13599	2600
$y=1$	898	903

Как запомнить названия ошибок

НЕТ эффекта, но его увидели!

1 рода – **не учил**, но **сдал**

(= знает по мнению экзаменатора)



ЕСТЬ эффект, но его НЕ увидели!

2 рода – **учил**, но **не сдал**


(= не знает по мнению экзаменатора)




	NEGATIVE ●	POSITIVE ● алгоритм
Кл. «0» ●	TRUE NEGATIVE	TYPE 1 ERR FALSE POSITIVE
Кл. «1» ●	TYPE 2 ERR FALSE NEGATIVE	TRUE POSITIVE
истина		

Точность

Accuracy



	$\sigma=0$	$\sigma=1$
$y=0$	13599	2600
$y=1$	898	903




$$\text{Accuracy} = \frac{\text{TN} + \text{TP}}{\text{TN} + \text{FN} + \text{TP} + \text{FP}}$$

Полнота

Sensitivity, True Positive Rate, Recall, Hit Rate

	$\hat{y}=0$	$\hat{y}=1$
$y=0$	13599	2600
$y=1$	898	903

Какой процент объектов положительного класса мы правильно классифицировали




$$TPR = R = \frac{TP}{TP + FN}$$

Точность

Precision, Positive Predictive Value

	$\hat{y}=0$	$\hat{y}=1$
$y=0$	13599	2600
$y=1$	898	903

Какой процент положительных объектов
(т.е. тех, что мы считаем положительными)
правильно классифицирован



$$PPV = P = \frac{TP}{TP + FP}$$

Специфичность

Specificity, True Negative Rate

	$\hat{y}=0$	$\hat{y}=1$
$y=0$	13599	2600
$y=1$	898	903

$$\text{TNR} = \text{Specificity} = R_0 = \frac{\text{TN}}{\text{TN} + \text{FP}}$$

Процент правильно классифицированных объектов негативного класса
«полнота для негативного класса»!

False Positive Rate

FPR, fall-out, false alarm rate

	$g=0$	$g=1$
$y=0$	13599	2600
$y=1$	898	903

$$\text{FPR} = \frac{\text{FP}}{\text{TN} + \text{FP}} = 1 - \text{TNR} = 1 - \text{Specificity}$$

Доля объектов негативного класса, которых мы ошибочно отнесли к положительному

F₁ score


$$\frac{2}{\frac{1}{P} + \frac{1}{R}} = \frac{2}{\frac{1}{\frac{TP}{TP+FP}} + \frac{1}{\frac{TP}{TP+FN}}} = \frac{2TP}{2TP+FP+FN}$$

F_β score


$$F_{\beta} = \frac{1}{\frac{\alpha}{P} + \frac{1-\alpha}{R}} = \frac{1}{\alpha} \frac{P \cdot R}{R + \left(\frac{1}{\alpha} - 1\right)P} = (1 + \beta^2) \frac{P \cdot R}{R + \beta^2 P}$$

$$\beta^2 = \left(\frac{1}{\alpha} - 1\right)$$


Почему используется F-мера




$$(P+R)/2$$



$$\sqrt{P \cdot R}$$




$$2 / (1/P + 1/R)$$




$$\min(P, R)$$


Почему используется F-мера



$$2 / (1/P + 1/R)$$




$$1 / (0.9/P + 0.1/R)$$



Можно сколь угодно улучшать один из показателей (R), если второй не увеличивается (P), то качество ограничено

Сбалансированная ТОЧНОСТЬ

Balanced Accuracy



Среднее арифметическое
чувствительности и специфичности

$$BA = \frac{R_1 + R_0}{2} = \frac{1}{2} \left(\frac{TP}{TP + FN} + \frac{TN}{TN + FP} \right)$$

Если классы примерно равномощны...

$$TP + FN \approx TN + FP \approx m / 2$$

Минутка кода

	score
cohen_kappa_score	0.24
accuracy_score	0.81
matthews_corrcoef	0.26
f1_score	0.34
roc_auc_score	0.67
balanced_accuracy_score	0.67

```
from sklearn.metrics import classification_report
print(classification_report(y_test, a_test)) # нужен print
```

	precision	recall	f1-score	support
0.0	0.94	0.84	0.89	16199
1.0	0.26	0.50	0.34	1801
micro avg	0.81	0.81	0.81	18000
macro avg	0.60	0.67	0.61	18000
weighted avg	0.87	0.81	0.83	18000

```
from sklearn.metrics import cohen_kappa_score
from sklearn.metrics import accuracy_score
from sklearn.metrics import matthews_corrcoef
from sklearn.metrics import f1_score
from sklearn.metrics import roc_auc_score
from sklearn.metrics import balanced_accuracy_score
```

Задача нечёткой бинарной классификации

Теперь выдаём оценку
принадлежности к классу 1

$$y \in \{0, 1\}$$

$$a \in [0, 1]$$

Кроме меток $\{0, 1\}$ возможны
промежуточные значения

Log Loss

В задаче классификации с двумя непересекающимися классами (0, 1),
когда ответ – **вероятность (?)** принадлежности к классу 1

$$\text{logloss} = -\frac{1}{m} \sum_{i=1}^m (y_i \log a_i + (1 - y_i) \log(1 - a_i))$$

BCE, Binary Cross Entropy

Bernoulli distribution

$$f(k; p) = \begin{cases} p & \text{if } k = 1, \\ q = 1 - p & \text{if } k = 0. \end{cases}$$


This can also be expressed as

$$f(k; p) = p^k (1 - p)^{1-k} \quad \text{for } k \in \{0, 1\}$$

Раздельная форма понятнее...


$$-\begin{cases} \log a_i, & y_i = 1, \\ \log(1 - a_i), & y_i = 0. \end{cases}$$

Нельзя ошибаться!



Log Loss

Оптимальная константа
для конечной выборки



$$-\frac{1}{m} \sum_{i=1}^m (y_i \log a + (1 - y_i) \log(1 - a)) \rightarrow \min_a$$

$$-\frac{m_1}{m} \log a - \frac{m_0}{m} \log(1 - a) \rightarrow \min_a$$

$$\frac{\partial \ln loss}{\partial a} = 0 \quad \Leftrightarrow \quad -\frac{m_1}{ma} + \frac{m_0}{m(1-a)} \Big|_{a(x,w)=const(x,w)} = 0 \quad \Leftrightarrow \quad a = \frac{m_1}{m}$$


ROC и AUC ROC

ROC = receiver operating characteristic

Функционал зависит не от конкретных значений, а от их порядка


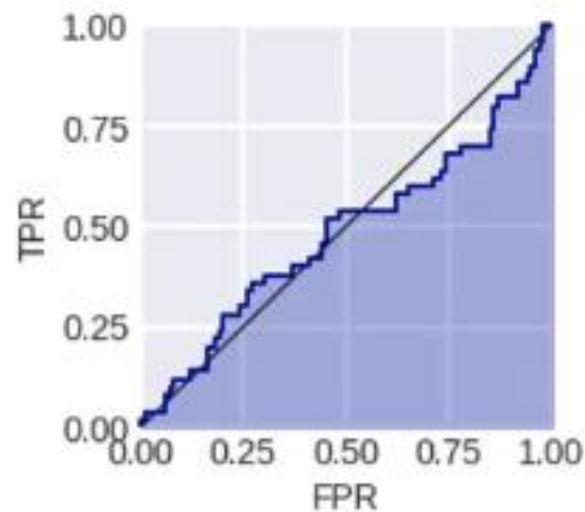
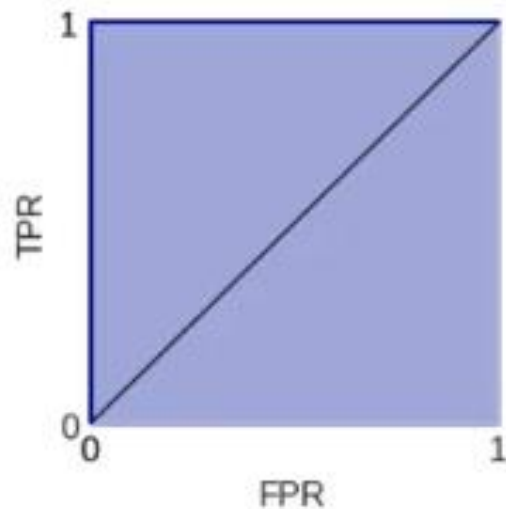
	оценка	класс
0	0.5	0
1	0.1	0
2	0.2	0
3	0.6	1
4	0.2	1
5	0.3	1
6	0.0	0

	оценка	класс	ответ
3	0.6	1	1
0	0.5	0	1
5	0.3	1	1
2	0.2	0	0
4	0.2	1	0
1	0.1	0	0
0	0.0	0	0



```
df['ответ'] = (df['оценка'] > 0.25).astype(int)
df.sort_values('оценка', ascending=False)
```

ROC и AUC ROC



Наилучший (AUC=1), случайный (AUC=0.5)
и наихудший (AUC=0) алгоритм

AUC = area under the curve

```
from sklearn.metrics import roc_curve  
fpr, tpr, thresholds = roc_curve(y_test, a)  
plt.plot(fpr, tpr, lw=3, c='#000099')
```

Смысл AUC


AUC ~ число правильно отсортированных пар (на рис. «кирпичики»)

Это сложно объяснить заказчику!

$$\text{AUC} = \frac{\sum_{i=1}^m \sum_{j=1}^m I[y_i < y_j] I[a_i < a_j]}{\sum_{i=1}^m \sum_{j=1}^m I[y_i < y_j]}$$

Чем хороша эта запись?

Что неправильно
(требуется пояснения) в формуле?



	оценка	класс	ответ
3	0.6	1	1
0	0.5	0	1
5	0.3	1	1
2	0.2	0	0
4	0.2	1	0
1	0.1	0	0
0	0.0	0	0


Смысл AUC

AUC ~ число правильно отсортированных пар (на рис. «кирпичики»)

Это сложно объяснить заказчику!

$$\text{AUC} = \frac{\sum_{i=1}^m \sum_{j=1}^m I[y_i < y_j] I[a_i < a_j]}{\sum_{i=1}^m \sum_{j=1}^m I[y_i < y_j]}$$


$$I[a_i < a_j] = \begin{cases} 1, & a_i < a_j, \\ 1/2, & a_i = a_j, \\ 0, & a_i > a_j. \end{cases}$$



	оценка	класс	ответ
3	0.6	1	1
0	0.5	0	1
5	0.3	1	1
2	0.2	0	0
4	0.2	1	0
1	0.1	0	0
0	0.0	0	0

GINI в машинном обучении

Кривая Лоренца (или CAP – Cumulative Accuracy Profile Curve)



PR = Positive Rate – процент объектов, которые при определённом выборе порога, отнесены к классу 1

Коэффициент Джини – отношение площадей

$$\frac{\text{Area under CAP curve}}{\text{Area under CAP curve} + \text{Area between CAP curve and ideal curve}} = 7/12$$


$$\text{gini} = 2 \text{AUCROC} - 1$$

GINI в задаче регрессии

Суммы страховых случаев:

5, 2, 10, 3, 0, 5, 0, 0

Так упорядочил алгоритм




Идеальный алгоритм:
10, 5, 5, 3, 2, 0, 0, 0

$\text{gini} \approx 0.57$

AUC ROC

+	в задачах, где важен порядок
+	учитывает разную мощность классов (не зависит от пропорций)
+	не важны значения, важен порядок
+	можно использовать для оценки признаков
-	«завышает» качество
-	оценивает не конкретный классификатор, а регрессию
-	сложно объяснить заказчику
-	не путать классификацию и регрессию



Ещё примеры кривых... «полнота-точность»

	оценка	класс
0 ^I	0.5	0
1	0.1	0
2	0.2	0
3	0.6	1
4	0.2	1
5	0.3	1
6	0.0	0

	оценка	класс	ответ
3	0.6	1	1
0	0.5	0	1
5	0.3	1	1
2	0.2	0	0
4	0.2	1	0
1	0.1	0	0
0	0.0	0	0

Порог = 0.25

Точность =

Полнота =

Ещё примеры кривых... «полнота-точность»

	оценка	класс		оценка	класс	ответ
0 ^I	0.5	0	3	0.6	1	1
1	0.1	0	0	0.5	0	1
2	0.2	0	5	0.3	1	1
3	0.6	1	2	0.2	0	0
4	0.2	1	4	0.2	1	0
5	0.3	1	1	0.1	0	0
6	0.0	0	0	0.0	0	0

Порог = 0.25

Точность = 2/3

Полнота = 2/3

Ещё примеры кривых... «полнота-точность»

	оценка	класс
0 ^I	0.5	0
1	0.1	0
2	0.2	0
3	0.6	1
4	0.2	1
5	0.3	1
6	0.0	0

	оценка	класс
3	0.6	1
0	0.5	0
5	0.3	1
2	0.2	0
4	0.2	1
1	0.1	0
0	0.0	0

Порог = 0.4
Точность =
Полнота =

Ещё примеры кривых... «полнота-точность»

	оценка	класс		оценка	класс	ответ
0 ^I	0.5	0	3	0.6	1	1
1	0.1	0	0	0.5	0	1
2	0.2	0	5	0.3	1	0
3	0.6	1	2	0.2	0	0
4	0.2	1	4	0.2	1	0
5	0.3	1	1	0.1	0	0
6	0.0	0	0	0.0	0	0

Порог = 0.4

Точность = 1/2


Полнота = 1/3

Ещё примеры кривых... «полнота-точность»

Площадь под кривой.. «Average Precision» (есть и другой смысл)

	оценка	класс
0 ¹	0.5	0
1	0.1	0
2	0.2	0
3	0.6	1
4	0.2	1
5	0.3	1
6	0.0	0

	оценка	класс	ответ
3	0.6	1	1
0	0.5	0	1
5	0.3	1	1
2	0.2	0	0
4	0.2	1	0
1	0.1	0	0
0	0.0	0	0



```
from sklearn.metrics import precision_recall_curve
precision, recall, thresholds = precision_recall_curve(y_test, a)
plt.plot(recall, precision)

# подсчитать площадь под кривой
from sklearn.metrics import auc
auc(recall, precision)

# или готовую функцию использовать
from sklearn.metrics import average_precision_score
```

Многоклассовая задача

«Multi-label»

Матрица классификаций

$$\| y_{ij} \|_{m \times l}$$

	class 1	class 2	class 3
0	1	0	0
1	0	1	0
2	0	0	1
3	1	1	0

Матрица ответов

$$\| a_{ij} \|_{m \times l}$$

	class 1	class 2	class 3
0	0.75	0.00	0.25
1	0.00	0.50	0.25
2	0.25	1.00	0.25
3	0.00	0.25	0.75

По сути, надо сравнить матрицы на похожесть

микро-подход	можно сравнивать матрицы как векторы
макро-подход	можно сравнивать столбцы матриц
по объектам	можно сравнивать строки матриц и усреднять

Многомерный AUC: минутка кода

```
from sklearn.metrics import roc_auc_score

roc_auc_score(y, a, average='macro')
# >0.9999999999999999

auc_pclass = [roc_auc_score(y[:,j], a[:,j]) for j in range(1)]
auc_pclass, mean(auc_pclass)

roc_auc_score(y, a, average='micro')
# >0.9999999999999999

roc_auc_score(y.ravel(), a.ravel())

roc_auc_score(y, a, average='weighted')
# >0.9999999999999999

w = y.sum(axis=0)
sum(np.array(auc_pclass) * w) / sum(w)

roc_auc_score(y, a, average='samples')
# >0.9999999999999999

auc_pinstance = [roc_auc_score(y[i,:], a[i,:]) for i in range(m)]
auc_pinstance, mean(auc_pinstance)
```

Многомерный AUC ROC

Матрица классификаций

	class 1	class 2	class 3
0	1	1	0
1	0	1	1
2	0	1	0
3	1	0	0

Матрица ответов

	class 1	class 2	class 3
0	0.7	0.6	0.5
1	0.3	0.4	0.6
2	0.5	0.9	0.2
3	0.4	0.5	0.1

macro	weighted	micro	samples
0.806	0.75	0.833	0.875

class 1	0.750
class 2	0.667
class 3	1.000

P_1	0.50
P_2	0.75
P_3	0.25

x_1	1.0
x_2	1.0
x_3	1.0
x_4	0.5

Многоклассовая задача: Log Loss

Cross-entropy

Естественное обобщение логистической ошибки

$$a_{ij} \in [0,1]$$

$$\text{logloss} = -\frac{1}{m} \sum_{i=1}^m \sum_{j=1}^l y_{ij} \log a_{ij}$$

тонкость: лучше для непересекающихся классов,

$\{a_{ij}\}_{j=1}^l \sim$ распределение

В задаче с пересекающимися классами (multi-label)

$$\text{logloss}_{\text{multi-label}} = -\frac{1}{l} \frac{1}{m} \sum_{j=1}^l \sum_{i=1}^m (y_{ij} \log a_{ij} + (1 - y_{ij}) \log(1 - a_{ij}))$$


$a_{ij} \in [0,1]$ макроусреднение logloss по классам

Сбалансированная точность «Balanced accuracy»

Макро-усреднение полноты

Сбалансированная точность (accuracy)
не есть усреднение точностей (precision)

$$BA = \frac{1}{l} \sum_{j=1}^l R_j = \frac{1}{l} \sum_{j=1}^l \frac{\sum_{i=1}^m I[y(x_i)_{[j]} = 1] I[a(x_i)_{[j]} = 1]}{\sum_{i=1}^m I[y(x_i)_{[j]} = 1]}$$



```
from sklearn.metrics import balanced_accuracy_score
```

Другие (неэквивалентные) определения:

$$BA = \frac{1}{l} \sum_{j=1}^l \min[P_j, R_j]$$

$$BA = \frac{1}{l} \sum_{j=1}^l \min[\text{sens}_j, \text{spec}_j]$$