

Системы искусственного интеллекта

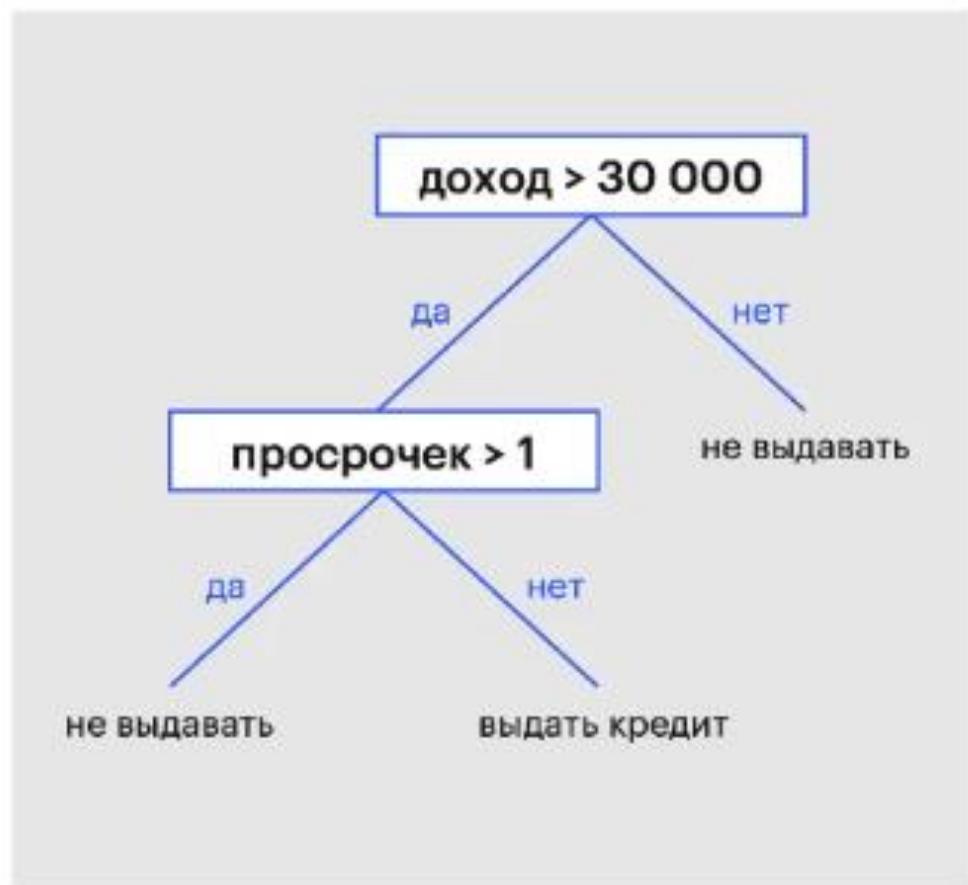
Лекция 6

Решающие деревья

(Дерево решений, Decision Tree)

Запорожцев Иван Федорович
zaporozhtsev.if.work@gmail.com

Решающее дерево (Decision Tree)



- **Лист или терминальная вершина** (leaf / terminal node) → метка (вероятности меток)
- **Внутренняя вершина** (internal node) → ветвление, предикат (признак, порог)
- **Дуга** → значение предиката

CART = Classification and Regression Trees

Бинарные деревья (binary trees) –
каждая вершина имеет двух потомков

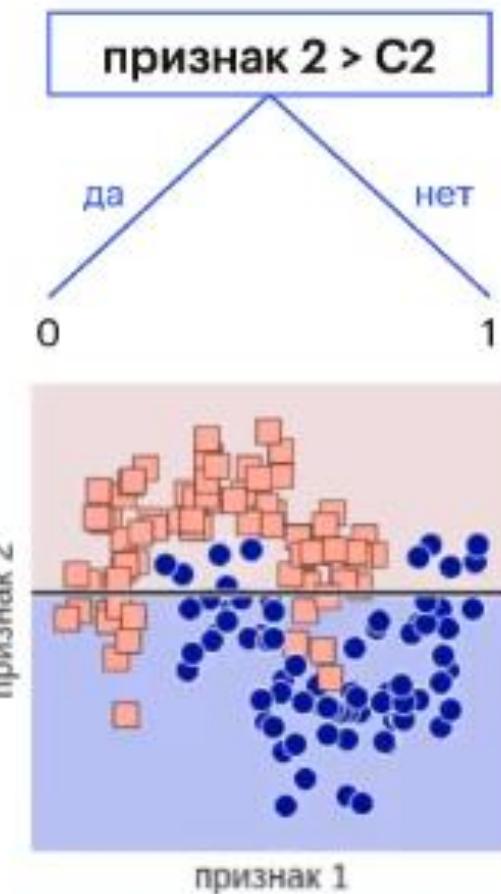
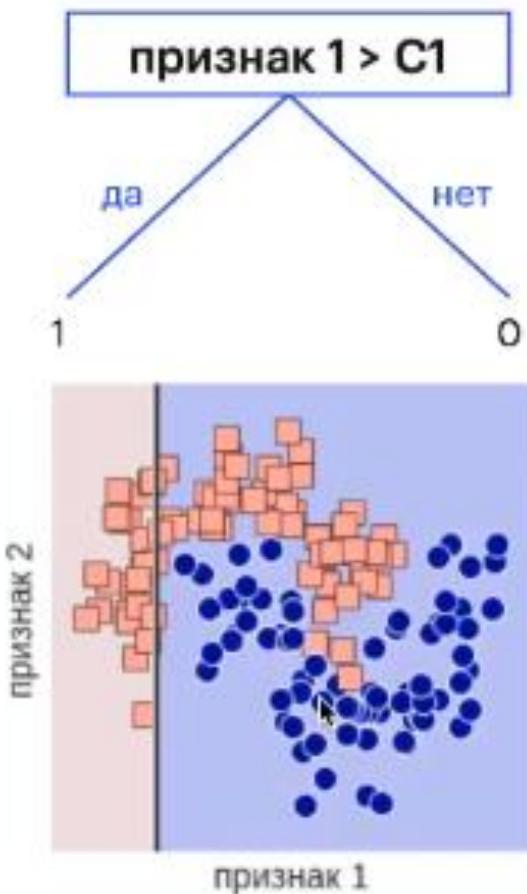
Дальше, в основном, рассматриваем их

Разбиение на области

Расщепление по переменной (splitting)

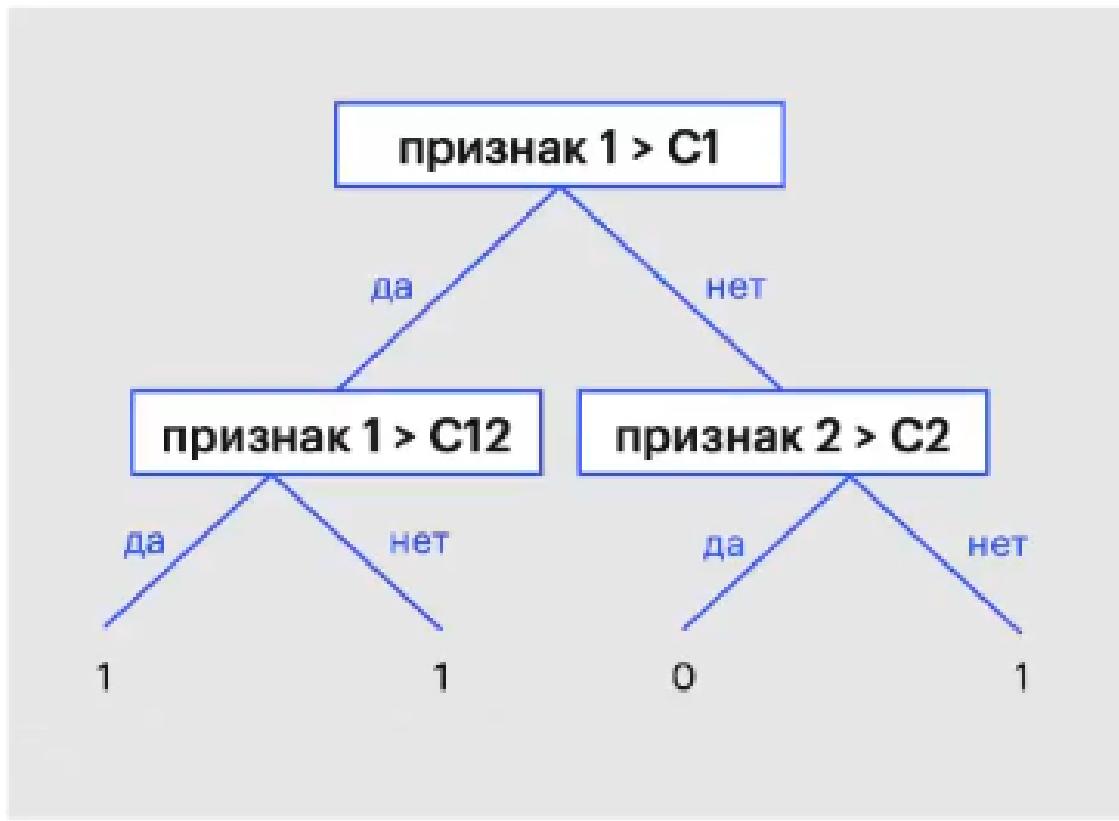


разбиение (stratifying / segmenting) на области / регионы



– это, кстати, «решающие пни» (decision stumps)

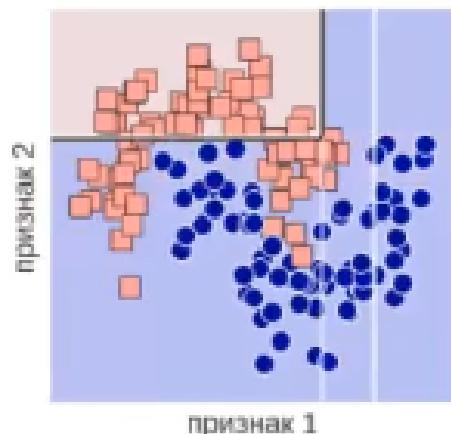
Решающее дерево как функция – кусочно-постоянная



$$a(x) = \sum_j a_{R_j} I[x \in R_j]$$

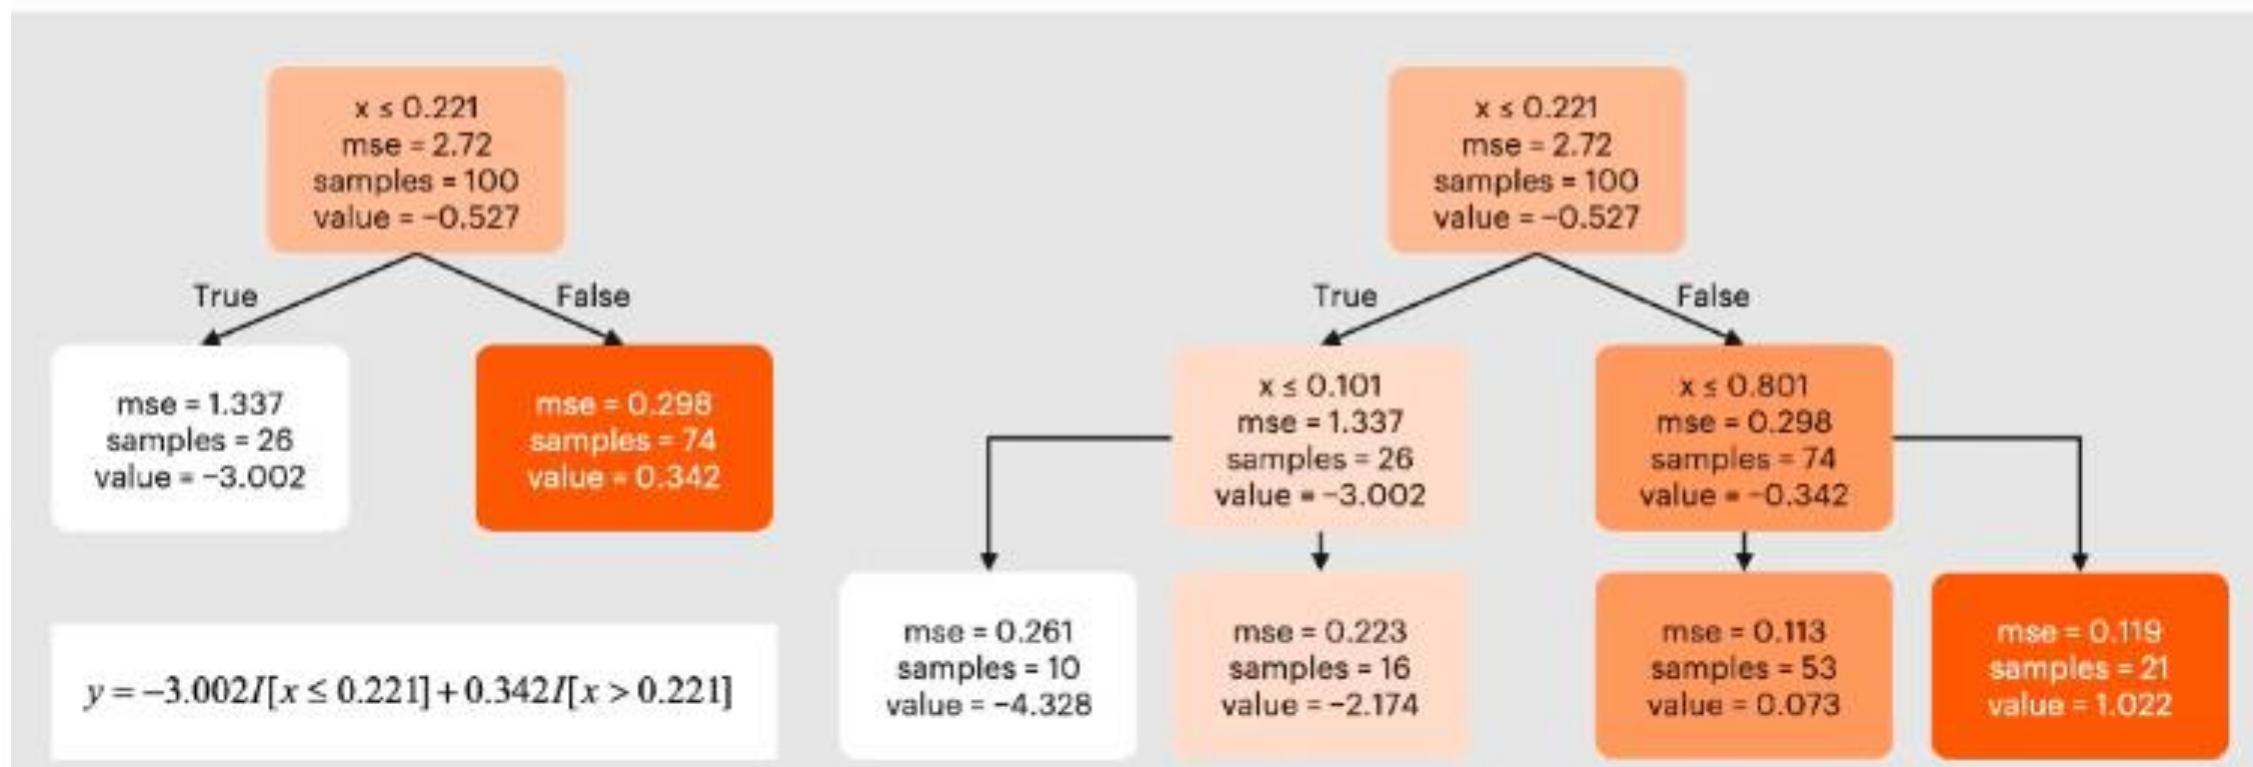
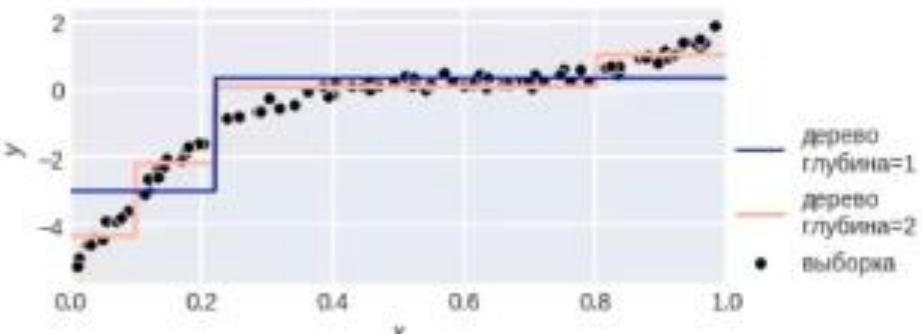
$$\bigcup_j R_j = \mathbb{N}$$

$$R_i \cap R_j = \emptyset \quad \forall i \neq j$$



В соседних регионах метки
могут быть одинаковые

Решающее дерево в задаче регрессии



Как строить дерево?

В идеале в задаче регрессии с MSE нужно решить такую задачу минимизации:

$$\sum_i \sum_j I[x_i \in R_j] (y_i - a_{R_j})^2 \rightarrow \min$$

– Residual Sum of Squares (RSS)

минимизация по всем разбиениям на области $\{R_j\}$
и по всем выборам a_{R_j}



Трудоёмко → строим дерево «по уровням»,
последовательно минимизируя RSS
(top-down greedy approach)

Построение дерева Сверху-вниз

Стартуя от дерева, состоящего из одной вершины, можно проводить расщепления выбирая признак и порог так, чтобы минимизировать RSS

Сейчас уточним – что будем оптимизировать



Расщепления производятся пока не выполняются некоторые критерии останова (ограничения на глубину дерева, число объектов обучающей выборки в листьях, на изменение RSS, см. дальше)

Построение дерева Приписывание меток областям

Заметим, что если зафиксировать область, то оптимальное значение метки для области находится просто (в смысле минимизации эмпирического риска)

В задаче регрессии (MSE)

$$a_{R_j} = \frac{1}{|\{x_i : x_i \in R_j\}|} \sum_{x_i \in R_j} y_i$$

В задаче классификации (точность)

$$a_{R_j} = \text{mode}(\{y_i : x_i \in R_j\})$$

Поэтому именно так они и выбираются!

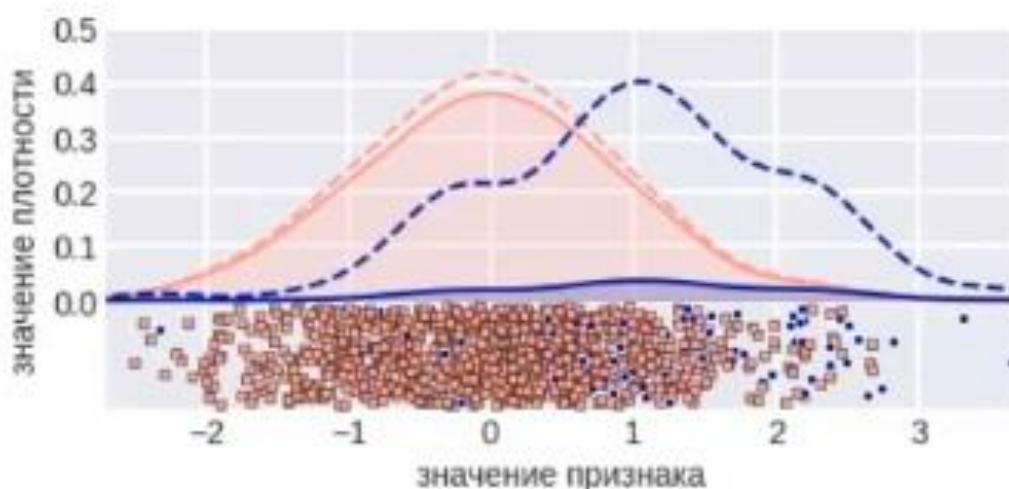
Возможно другие значения для специальных функционалов качества

Построение дерева

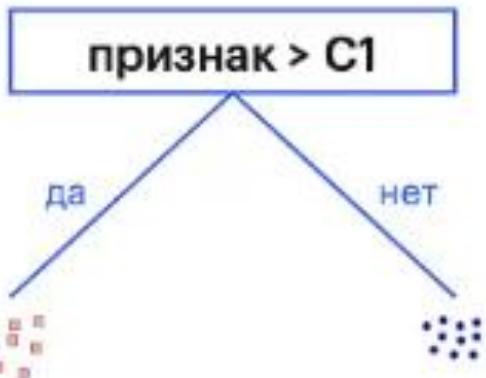
Как делать расщепления



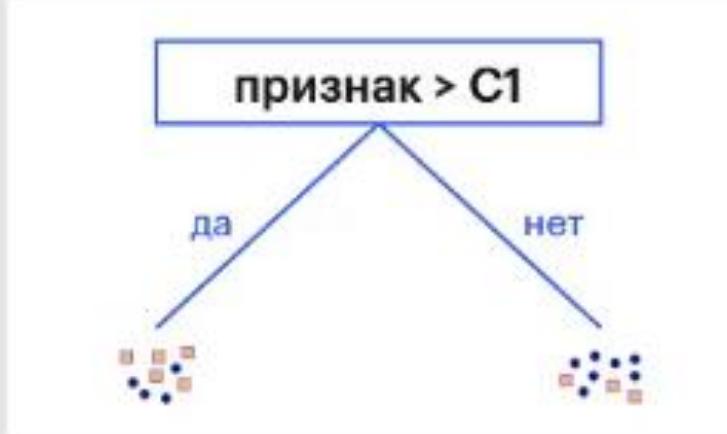
Как выбрать порог для расщепления
при построении дерева?



«Хорошо»:



«Плохо»:

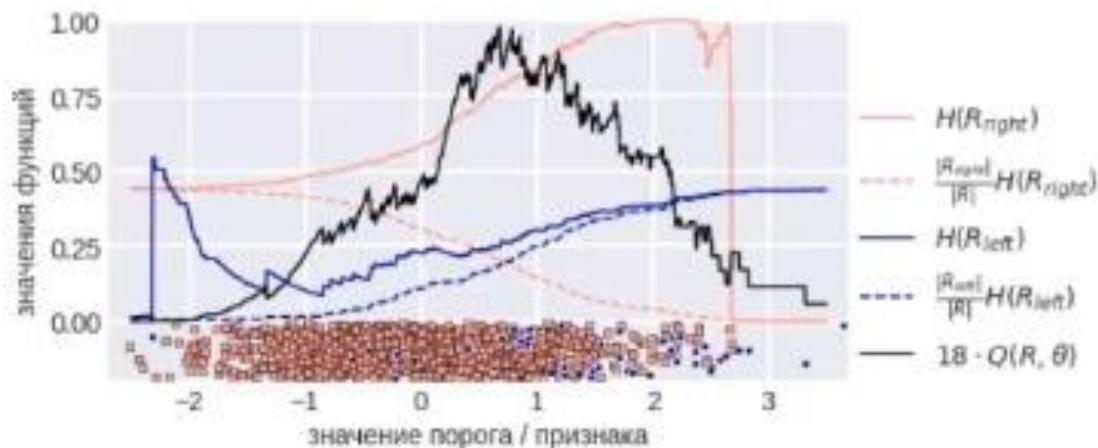


Критерии расщепления в задачах классификации

Идея: ввести меру неоднородности / зашумлённости (impurity) множества $H(R)$

~ насколько в области «почти все объекты одного класса»
при расщеплении области R на R_{left} и R_{right} оптимизировать

$$Q(R, \theta) = H(R) - \frac{|R_{\text{left}}|}{|R|} H(R_{\text{left}}) - \frac{|R_{\text{right}}|}{|R|} H(R_{\text{right}})$$



Меры impurity

Неоднородности / зашумлённости

В задачах классификации

Пусть есть область R

в ней доли объектов всех классов: p_1, \dots, p_l

Missclassification criteria $\longrightarrow H(R) = 1 - p_{\max}$

Энтропийный $\longrightarrow H(R) = - \sum_j p_j \log_2 p_j$

Джини $\longrightarrow H(R) = \sum_j p_j(1 - p_j) = 1 - \sum_j p_j^2$

Мера неоднородности (impurity)
минимальна (=0) только если все объекты
принадлежат одному классу

Критерии расщепления Частный случай двух классов

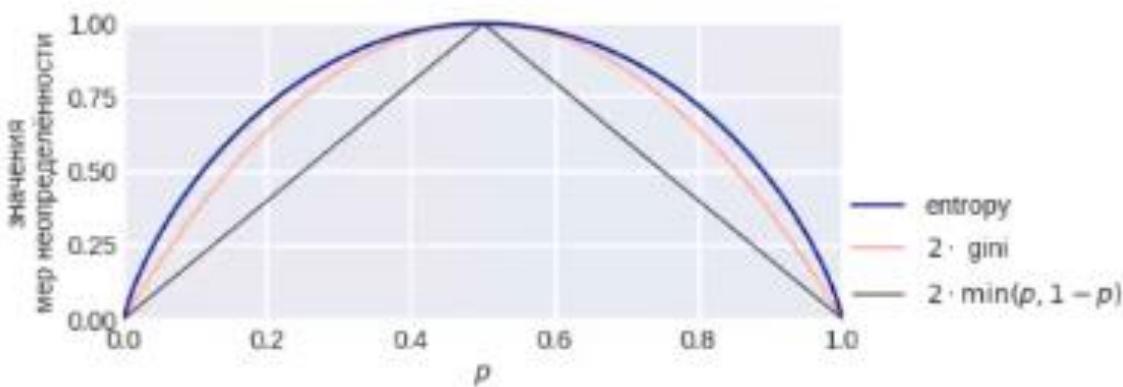
Пусть есть область R

в ней доли объектов всех классов: $p_1 = p, p_2 = 1 - p$

Missclassification criteria $\longrightarrow H(R) = \min[p, 1 - p]$

Энтропийный $\longrightarrow H(R) = -p \log_2 p - (1 - p) \log_2 (1 - p)$

Джини $\longrightarrow H(R) = 2p(1 - p) = 1 - p^2 - (1 - p)^2$



Критерии расщепления

4

AUC_ROC (не будем обосновывать)

$$Q(R, \theta) = \left| \frac{|R_{\text{right}} \cap K_0|}{|K_0|} - \frac{|R_{\text{right}} \cap K_1|}{|K_1|} \right| = \\ = \left| \frac{|R_{\text{left}} \cap K_0|}{|K_0|} - \frac{|R_{\text{left}} \cap K_1|}{|K_1|} \right|$$

5

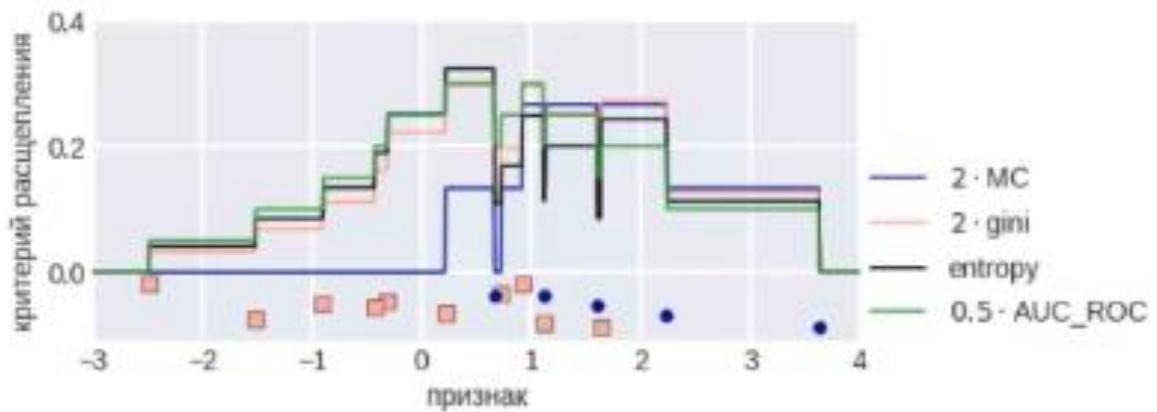
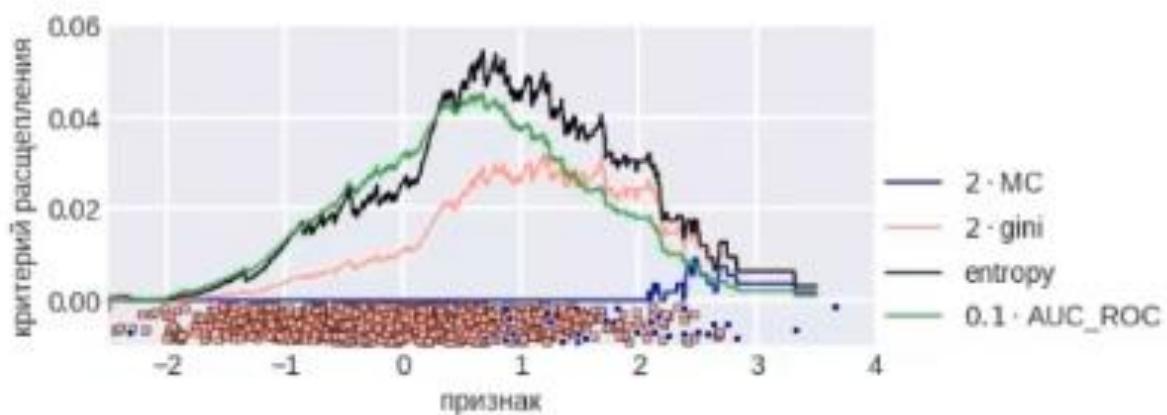
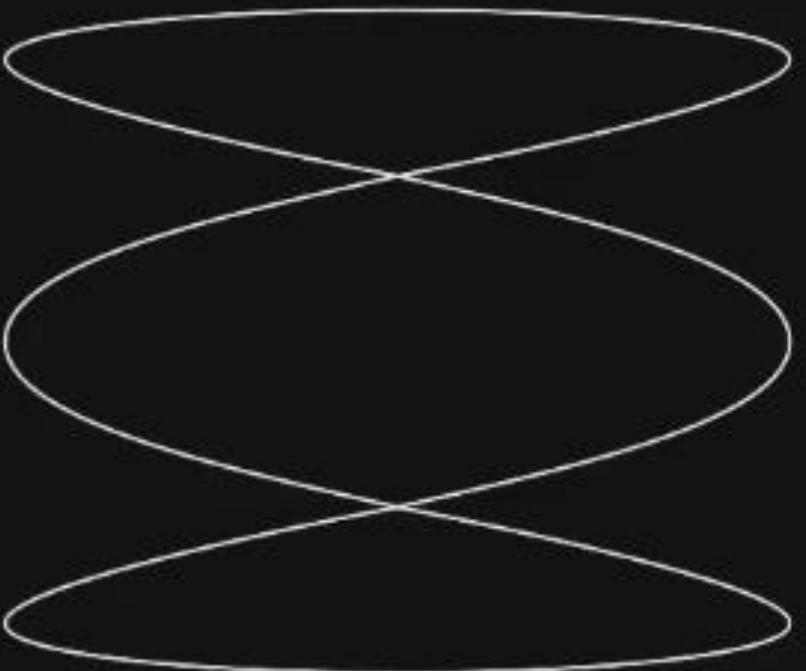
Twoing

$$Q(R, \theta) = \frac{1}{4} \frac{|R_{\text{left}}|}{|R|} \frac{|R_{\text{right}}|}{|R|} \left(\sum_{j=1}^l |p_j(R_{\text{left}}) - p_j(R_{\text{right}})| \right)^2$$

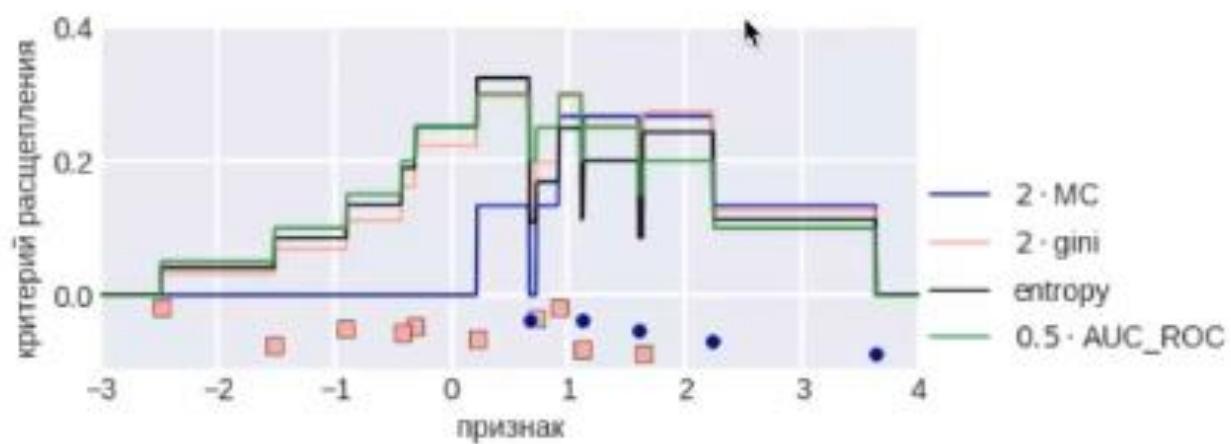
Для двух классов ~ Джини

Критерии расщепления

Частный случай двух классов



Энтропия – мера неопределённости распределения



При пороге $\theta = 1$

$$\frac{|R_{\text{left}}|}{|R|} = \frac{9}{15} \quad \frac{|R_{\text{right}}|}{|R|} = \frac{6}{15}$$

$$H(R) = -(5/15)\log_2(5/15) - (10/15)\log_2(10/15) \approx 0.918$$

$$H(R_{\text{right}}) = -(4/6)\log_2(4/6) - (2/6)\log_2(2/6) \approx 0.918$$

$$H(R_{\text{left}}) = -(1/9)\log_2(1/9) - (8/9)\log_2(8/9) \approx 0.503$$

$$Q(R, \theta) \approx 0.918 - \frac{9}{15}0.503 - \frac{6}{15}0.918 \approx 0.249$$

Напоминание Теория информации

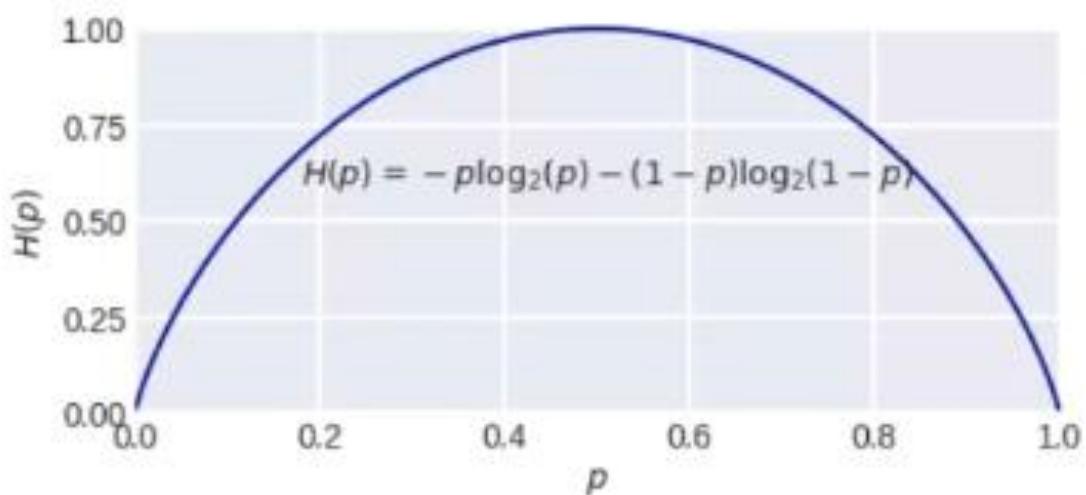
Информационная энтропия
(Entropy) – мера неопределённости
некоторой системы

$x \sim (x_1, p_1), (x_2, p_2), \dots$

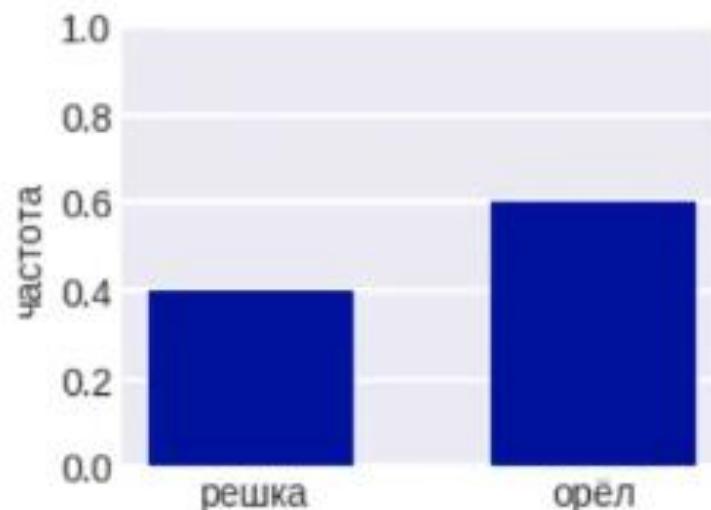
$$H(x) = -\sum_t p_t \log p_t$$

$$H(p) = -p \log_2 p - (1-p) \log_2 (1-p)$$

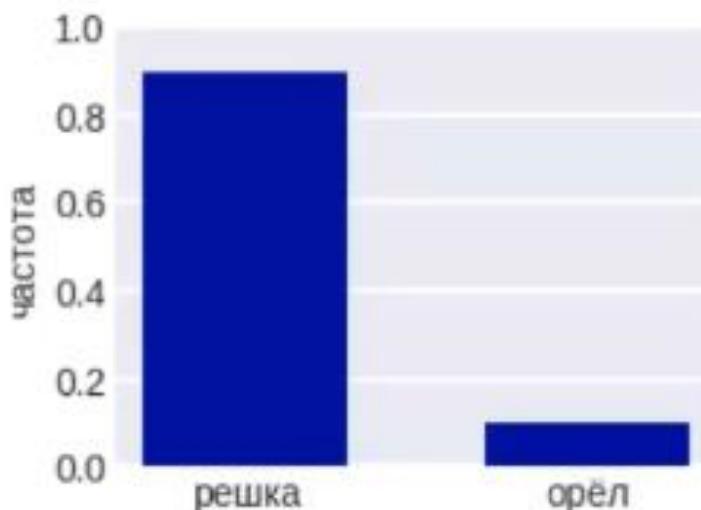
Что зависит от основания логарифма?



Напоминание: теория информации



$$-\frac{4}{10} \log_2 \frac{4}{10} - \frac{6}{10} \log_2 \frac{6}{10} \approx 0.97$$



$$-\frac{9}{10} \log_2 \frac{9}{10} - \frac{1}{10} \log_2 \frac{1}{10} \approx 0.47$$

Результат подбрасывания честной монеты – 1 бит информации

Обоснование энтропийного критерия расщепления

	облачно	ясно
дождь	3	1
сухо	1	5

$X = \{\text{дождь, сухо}\}$

$Y = \{\text{облачно, ясно}\}$

Совместная энтропия

$$H(X, Y) = -\sum_{x \in X} \sum_{y \in Y} p(x, y) \log_2 p(x, y) = \\ = -\frac{3}{10} \log_2 \frac{3}{10} - \frac{1}{10} \log_2 \frac{1}{10} - \frac{1}{10} \log_2 \frac{1}{10} - \frac{5}{10} \log_2 \frac{5}{10}$$

Энтропия при условии **знаем, что дождь**

$$H(Y | X = x) = -\sum_{y \in Y} p(y | x) \log_2 p(y | x) = \\ = -\frac{3}{4} \log_2 \frac{3}{4} - \frac{1}{4} \log_2 \frac{1}{4}$$

Обоснование энтропийного критерия расщепления

	облачно	ясно
дождь	3	1
сухо	1	5

$X = \{\text{дождь, сухо}\}$

$Y = \{\text{облачно, ясно}\}$

Ожидаемая условная энтропия

$$H(Y | X) = \sum_{x \in X} p(x)H(Y | X = x)$$

Энтропия при условии, что знаем X

Information Gain / **Mutual Information**

$$IG(Y | X) = H(Y) - H(Y | X)$$

Насколько знание X уменьшило неопределённость

Как раз это и считаем!

$$Q(R, \theta) = H(R) - \frac{|R_{\text{left}}|}{|R|}H(R_{\text{left}}) - \frac{|R_{\text{right}}|}{|R|}H(R_{\text{right}})$$

Критерии расщепления Тонкости

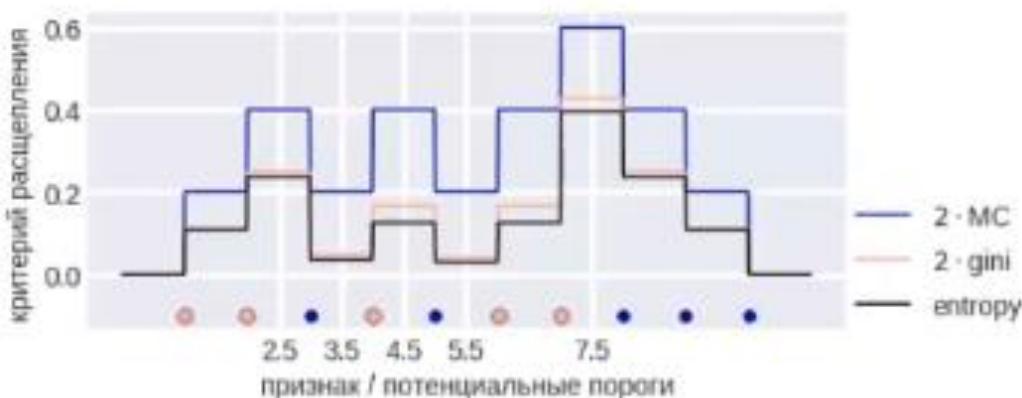
При выборе расщепления мы выбираем порог

- достаточно рассматривать только «средние точки»
- достаточно рассматривать только «границы регионов»

Но в чём тут подвох?



Для начала надо отсортировать все значения
Есть проблема константных признаков



Критерии расщепления в задачах регрессии

Аналогично... но тут
«неоднородность» – дисперсия

$$H(R) = \text{var}(\{y_i \mid y_i \in R\})$$

$$Q(R, \theta) = H(R) - \frac{|R_{\text{left}}|}{|R|} H(R_{\text{left}}) - \frac{|R_{\text{right}}|}{|R|} H(R_{\text{right}})$$

Делаем разбиение, которое максимизирует Q
Повторяем процедуру в листьях

Кстати, для бинарной
случайной величины $y_i \in \{0,1\}$

Моменты распределения Бернулли [пр

$$\mathbb{E}[X] = p,$$

$$\mathbb{D}[X] = p(1 - p) = pq, \text{ так как:}$$

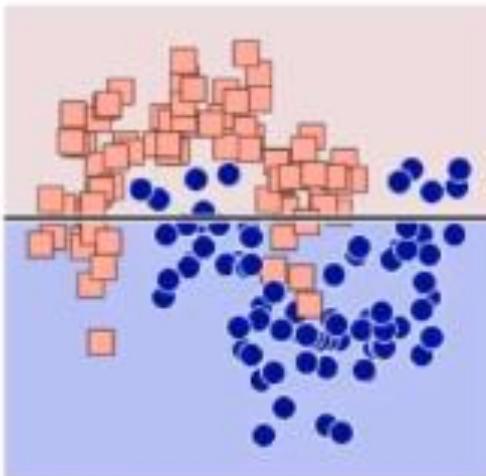
$$\mathbb{E} X^2 - (\mathbb{E} X)^2 = p - p^2 = p \cdot (1 - p) = pq$$

GINI

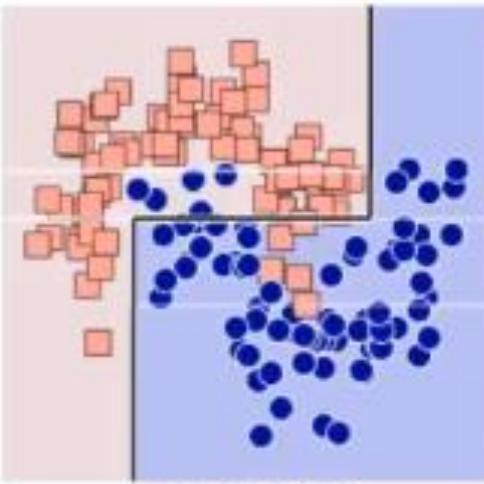
Как долго строить дерево

Критерии останова

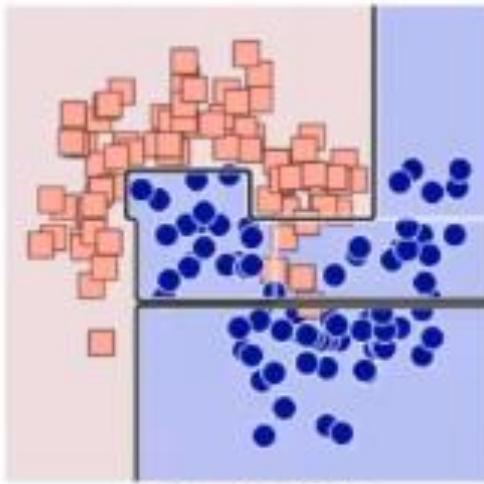
- ограничение на глубину / на число листьев
- ограничение на число объектов в листьях / на число, когда делаем деление
- «естественное ограничение» (все объекты одного класса) обобщение: почти все объекты одного класса
- изменение impurity



max_depth=1



max_depth=3



max_depth=5

Минутка кода: «Решающее дерево»

```
from sklearn.tree import DecisionTreeClassifier

model = DecisionTreeClassifier(criterion='gini',          # критерий разделения
                                # «гини» / «коткорум»
                                splitter='best',           # разбиение «лучше» / «худшее»
                                max_depth=None,            # допустимая глубина
                                min_samples_split=2,       # минимальная выборка для разбиения
                                min_samples_leaf=1,         # минимальная масса листа
                                min_weight_fraction_leaf=0.0, # минимально с весом
                                max_features=None,         # признаков для каждого разбиения
                                random_state=3,             # допустимое число листьев
                                max_leaf_nodes=None,        # порог изменения «минимальности»
                                min_impurity_decrease=0.0,   # порог «минимизированности» для остановки
                                min_impurity_split=None,    # масса классов («balanced» или «однород»)
                                class_weight=None,          # для подсчетов
```



```
model.fit(X, y)
```

Особенности

Изменение impurity – порог на

$$\frac{|R|}{m} \left(H(R) - \frac{|R_{\text{left}}|}{|R|} H(R_{\text{left}}) - \frac{|R_{\text{right}}|}{|R|} H(R_{\text{right}}) \right)$$

$$Q(R, \theta) = H(R) - \frac{|R_{\text{left}}|}{|R|} H(R_{\text{left}}) - \frac{|R_{\text{right}}|}{|R|} H(R_{\text{right}})$$

Проблема переобучения деревьев

Глубокие деревья
склонны к переобучению,
поскольку «затачиваются»
на отдельные объекты

- 1 Прекращают построение достаточно рано
(см. критерии останова, stopping early)

Можно на отложенной выборке выбрать точку останова

- 2 Подрезают деревья (post-pruning)

- 3 Используют в ансамблях
(например, в случайном лесе)

Отдельная тема

Подрезка (post-pruning)

Сейчас используется редко – если задачу надо решить деревом
(или ансамблем из нескольких деревьев)



Раньше...

- использовали отложенный контроль (удаляли листья, если это повышает качество)
- MDL (Minimum Description Length)

$$\sum_j \sum_{x_i \in R_j} (y_i - a_{R_j})^2 + \alpha |\{R_j\}| \rightarrow \min$$

Оптимальное значение α находят с помощью скользящего контроля, потом с этим значением параметра дерево перестраивается по всей выборке



α регулирует баланс между стремлением обучиться и получить небольшое дерево

Важности признаков

Вспомним формулу $\rightarrow Q(R, \theta) = H(R) - \frac{|R_{\text{left}}|}{|R|} H(R_{\text{left}}) - \frac{|R_{\text{right}}|}{|R|} H(R_{\text{right}})$

– это уменьшение неоднородности при выборе такого расщепления!

Идея: чем больше признак уменьшает неоднородность, тем он важнее!

Важность признака = сумма уменьшений неоднородностей с помощью этого признака при построении дерева (иногда умножается на $|R|$ ~ sklearn)

Есть и другие способы оценки важности:

- коэффициенты в моделях
- ОOB-оценки
- корреляции / функциональные зависимости и т.п.

Деревья: проблема пропусков

Missing Values

- Удалить
- Заменить (средним)
- Рассматривать как отдельную категорию
- Пронести в обе ветви дерева
- Выбрать наиболее подходящую ветвь дерева
- Суррогатные расщепления (Surrogate Splits)

Суррогатные расщепления

Surrogate Splits

Для объектов, у которых расщепляемая переменная неизвестна подбираем другой сплит, который имитирует изначальный

A	B	C	Y=target
0	?	0	0
1	5	1	0
2	?	0	0
3	8	1	1
?	7	1	1
?	7	1	1

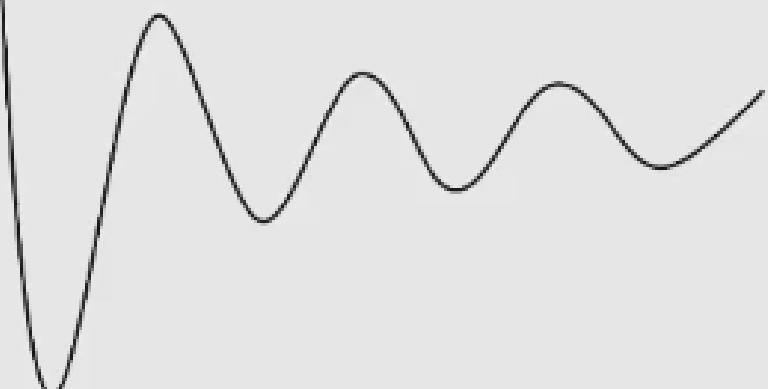
«A > 2.5», но не понятно, в какое поддерево
класть последние два объекта

«B > 6» на объектах с известными значениями
признаков совпадает с исходным,

При этом определено для тех объектов, у которых
были неизвестны значения признака A.

www.learnbymarketing.com/methods/

Деревья: категориальные признаки



Формально при расщеплении должны
рассмотреть все подмножества
множества категорий

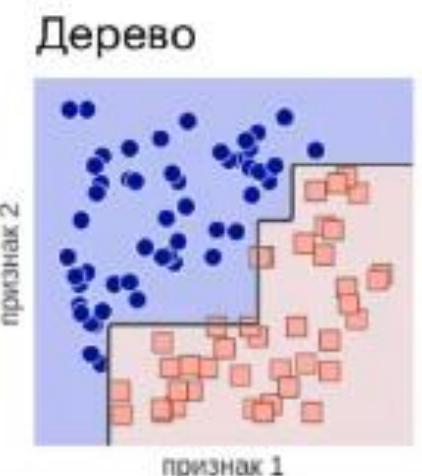


Реально (в задаче бинарной классификации):
упорядочиваем по вероятности класса 1,
каждая категория → номер по порядку

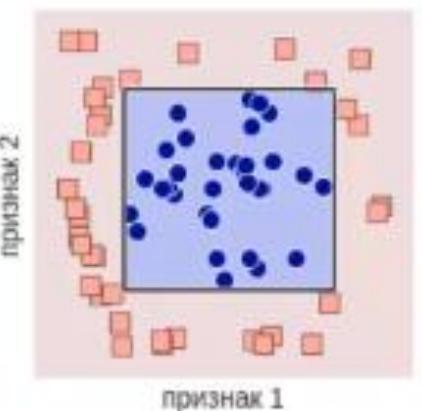
- находим для полученного числового признака оптимальное разбиение
- переобучение для мелких категорий

Деревья vs линейные модели

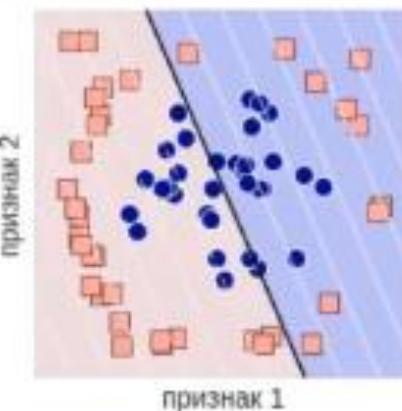
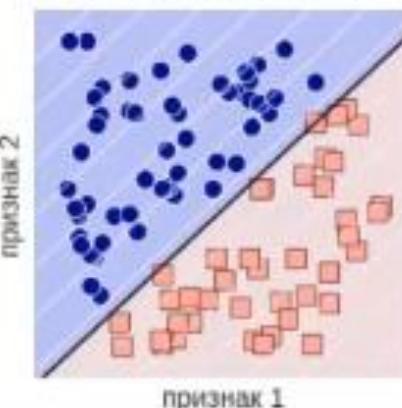
Линейная зависимость



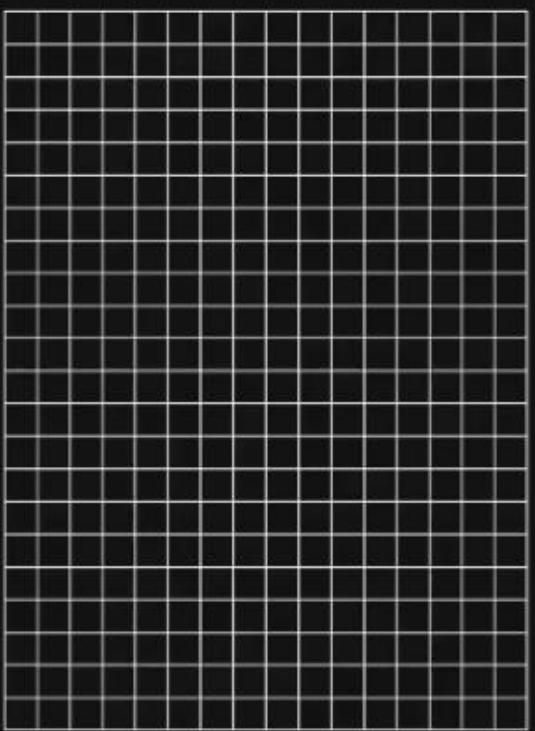
Нелинейная зависимость



Гиперплоскость



Итог: решающие деревья



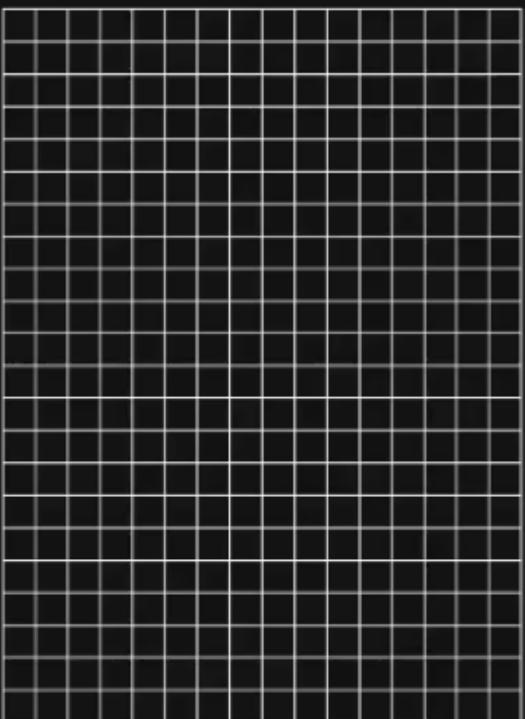
Возможности

- способны обучаться на любой (непротиворечивой) выборке (при возможности построения неограниченного дерева)
- можно использовать при признаках разных типов (+ пропуски)
- можно сделать устойчивыми к выбросам
- универсальный метод – для всех типов задач машинного обучения
- встроенный отбор признаков
- нелинейный метод!

Качество

- не очень высокое качество решения задачи / переобучение
- хороши в ансамблях **будет в ансамблировании**

Итог: решающие деревья



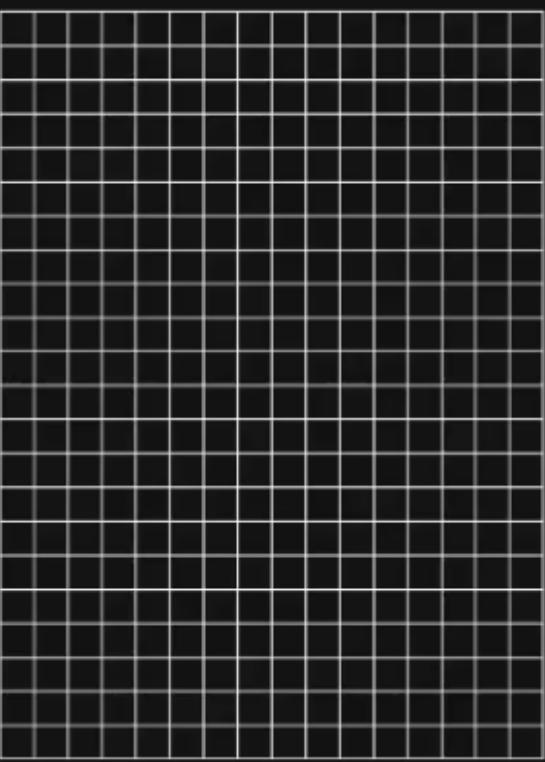
Эффективность / стабильность

- достаточно быстро строятся
- нет ограничений на распределения признаков
- «неустойчивый алгоритм» (меняется при небольшом изменении выборки)
- плох для больших / изменяющихся данных

Понимание, интерпретация и анализ

- просто объяснить неспециалисту
- ближе к человеческой логики принятия решения
- можно изобразить (на слайде)
- нет красивой аналитической формулы для модели

Итог: решающие деревья



Особенности

- не использует геометрию (нет расстояний, неметрический)
- устойчив к масштабированию
- устойчив к дубликатам признаков, зависимостям в признаках и т.п.
- автоматическое решение проблемы пропусков
- неспособен к экстраполяции
- использует мало признаков!!!

Важно: эвристическое жадное обучение

(т.к. построение оптимального дерева очень сложная – NP-полная – задача)

Если категориальные признаки с большим числом категорий – всё сваливается на них...

Спасибо за внимание!



Запорожцев Иван Федорович
zaporozhtsev.if.work@gmail.com